2026

Fundamentos de la Ciencia de Datos

Trabajo Práctico Especial

Grupo 2

Ferretjans, Martín.

Liotti, Juan Ignacio.

Williams, Santiago.

1. Introducción

Para este análisis inicial, pudimos comprobar el origen de los datos de manera oficial, utilizando la documentación de Open Food Facts, la cuál plantea que uno de sus pilares es la confianza en el aporte voluntario, lo que da a entender que los datos son cargados voluntariamente por cualquier persona mediante fotografías de las tablas nutricionales de cada producto.

El dataset contiene información sobre productos alimenticios, entre las que podemos encontrar sus ingredientes, calificaciones de calidad nutricional, grado de procesamiento e impacto ambiental, así como sus alérgenos y su tabla nutricional.

El dataset presenta 4997 filas las cuales cada una de ellas representa un alimento distinto, y cada uno de ellos viene representado por los siguientes atributos:

Nombre	Clasificación	Descripción
product_name	Cualitativa nominal	Nombre del producto
brands	Cualitativa nominal	Marcas
categories	Cualitativa nominal	Categorías del alimento
ingredients	Cualitativa nominal	Lista de ingredientes
nutriscore_grade	Cualitativa ordinal	Clasificación de calidad nutricional (A = más saludable, E = menos saludable)
nova_group	Cuantitativa discreta	Escala que mide el grado de procesamiento de los alimentos (1 sin procesar o muy levemente, 4 ultra procesado)
ecoscore_grade	Cualitativa ordinal	Clasificación de impacto ambiental del producto.
allergens	Cualitativa nominal	Alérgenos presentes en el alimento.
energy_kcal	Cuantitativa contínua	Cantidad de calorías en una porción del alimento.
fat_100g	Cuantitativa contínua	Cantidad de grasas en 100 gramos de producto
saturated_fat_100g	Cuantitativa contínua	Cantidad de grasas saturadas en 100 gramos de producto
carbs_100g	Cuantitativa contínua	Cantidad de carbohidratos en 100 gramos de producto

sugars_100g	Cuantitativa contínua	Gramos de azúcares en 100 gramos de producto
fiber_100g	Cuantitativa contínua	Gramos de fibras en 100 gramos de producto
proteins_100g	Cuantitativa contínua	Gramos de proteínas en 100 gramos de producto
salt_100g	Cuantitativa contínua	Gramos de sal en 100 gramos de producto
sodium_100g	Cuantitativa contínua	Gramos de sodio en 100 gramos de producto
contains_gluten	Cualitativa nominal dicotómica	Si contiene gluten
contains_dairy	Cualitativa nominal dicotómica	Si contiene lácteos
contains_nuts	Cualitativa nominal dicotómica	Si contiene nueces
contains_soy	Cualitativa nominal dicotómica	Si contiene soja
contains_eggs	Cualitativa nominal dicotómica	Si contiene huevo
contains_fish	Cualitativa nominal dicotómica	Si contiene pescado
food_type	Cualitativa nominal	Tipo de envasado

Operaciones de limpieza:

Como primera medida, decidimos eliminar la columna “food_type”, ya que vimos que absolutamente todas las muestras tienen el mismo valor (Branded/Packaged). Esto nos puede llevar a pensar dos cosas, que los datos fueron mal tomados, o que todos los productos son producidos por marcas y vendidos en supermercados de forma “brandeada”. Esta última es la que más sentido cobra ya que casi la totalidad de las filas tienen una marca asignada, y nunca se habla de un alimento en sí mismo.

Otra medida que tomamos fue eliminar aquellos productos que no tienen ni nombre ni marca, es una obviedad pero lo hicimos ya que no aportan nada al análisis.

Por otro lado, notamos ciertas inconsistencias en aquellas columnas que representan cantidades de nutrientes cada 100 gramos. Había ciertas filas cuyos valores superan esta cantidad, lo cual no tiene ningún tipo de sentido. También eliminamos otras inconsistencias

nutricionales, como por ejemplo aquellos productos que tenían más gramos de grasas saturadas que de grasas cada 100 gramos. Y también aquellos que tienen más azúcares y carbohidratos que calorías.

Luego eliminamos aquellas filas que tienen calorías negativas y las que tienen más de 900 calorías cada 100 gramos, lo cuál no es posible, ya que como máximo 1 gramo de grasa tiene 9 calorías (máximo aporte calórico de los nutrientes presentados) y solo se llega a esa cantidad teniendo 100 gramos de grasas cada 100 gramos de alimento.

A la hora de analizar las categorías y alérgenos de los alimentos, notamos que los valores no solo aparecían en diversos idiomas, sino que también venían precedidos por la abreviación del idioma, por ejemplo “en:milk”. Para comenzar la limpieza de estas columnas, primero eliminamos la expresión regular del inicio de cada palabra. Esto no fue suficiente, ya que los alérgenos y categorías quedaron dispersos en varios idiomas, por lo tanto, había casos donde un alimento que tenía la misma información que otro, no se contabilizaba correctamente. A partir del uso de los diccionarios de Python pudimos resolver esto.

Por último, transformamos las variables cualitativas ordinales a números utilizando ordinal encoding para poder utilizarlas en los tests, los cuales funcionan con números.

2. Análisis exploratorio de los datos

2.1: Columna “food_type” no aporta valor.

Para el análisis preliminar de los datos, comenzamos mostrando la distribución de la columna “food_type” (justificación en sección 1).

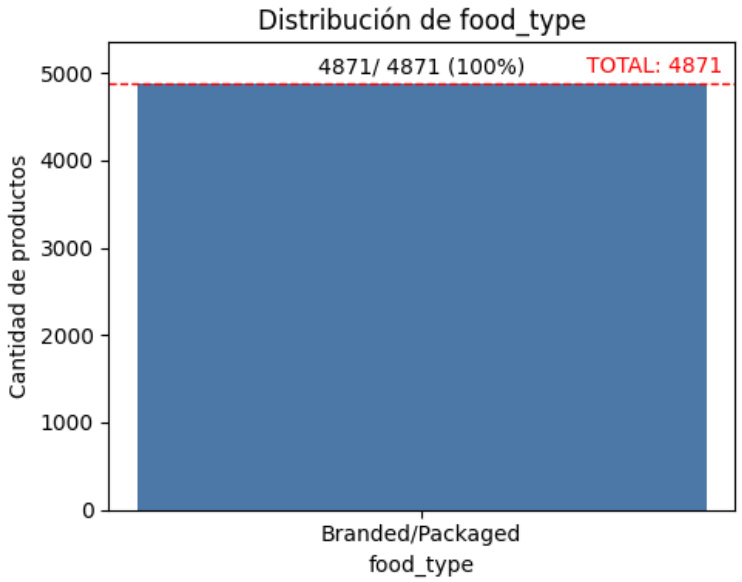


Fig. 1: Gráfico de barras que representa la distribución de la variable “food_type”.

2.2: Valores absurdos en ingredientes cada 100 gramos.

Otra cuestión que se planteó a la hora de realizar la limpieza de datos, fue la de que existían filas que contenían valores mayores a 100 gramos en columnas que indican la cantidad en gramos que había de determinado ingrediente cada 100 de producto (justificación en sección 1).

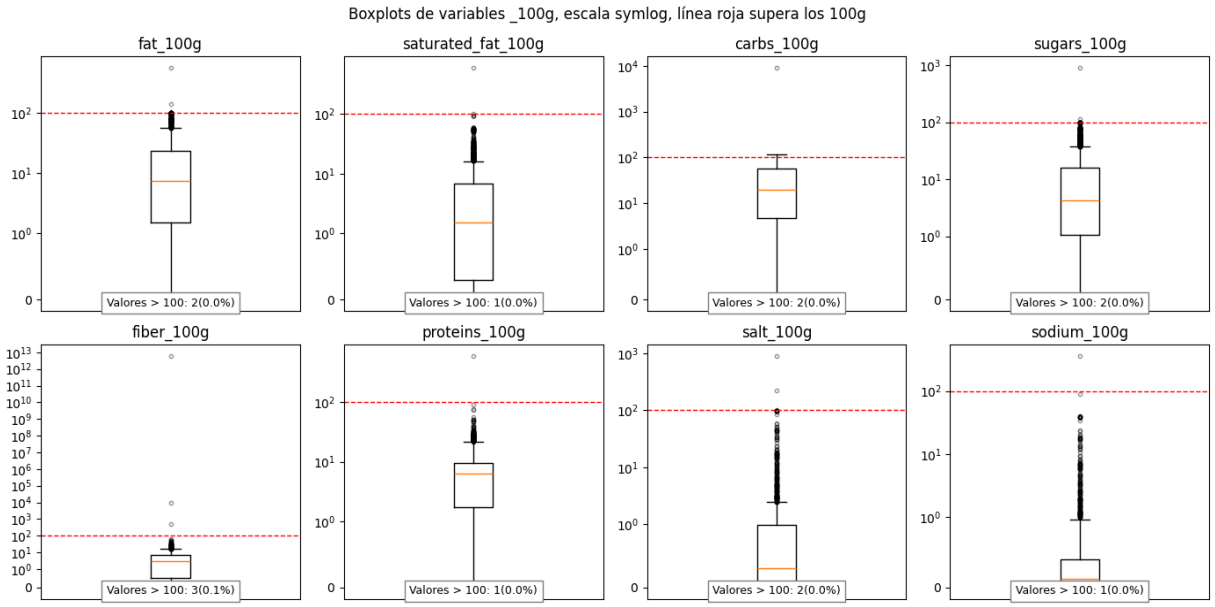


Fig. 2: Esta figura es un boxplot de cada variable terminada en "_100g", donde la línea roja representa el límite de un valor absurdo (> 100g).

2.3: Análisis en variables categóricas:

Como último análisis, decidimos incluir un gráfico de barras donde se muestran los valores de las variables categóricas "nutriscore_grade", "nova_group" y "ecoscore_grade". Con el fin de conocer los valores predominantes en cada una de estas categorías.

Con estos valores, podemos concluir, por ejemplo, que el 53.5% de los productos cargados en el dataset que tienen valores no nulos, tienen un alto nivel de procesamiento.

Además, vemos que el valor más predominante dentro del gráfico de Eco-score es "Sin Dato".

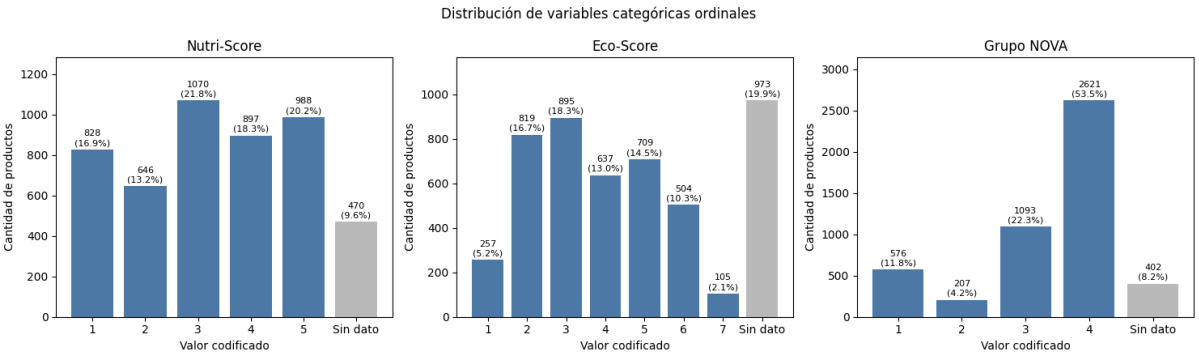


Fig. 3: Gráfico de barras para cada variable categórica "Nutri-Score", "Eco-Score", "Grupo NOVA".

3. Hipótesis y resolución

3.1. Hipótesis 1: Verificar la existencia de gluten en más del 50% de los alimentos

3.1.1. Definición de la hipótesis

H0: Más del 50% de los alimentos contienen gluten.

Esta hipótesis se nos ocurrió al notar las dificultades que tienen en el día a día las personas intolerantes al gluten para abordar su alimentación. Al notar esta columna, rápidamente pensamos que la gran mayoría tendría gluten, ya que hoy en día, o bien contienen gluten, o bien no hacen los controles necesarios, por lo que los productos podrían estar expuestos a contaminación, conteniendo gluten igualmente.

3.1.2. Estrategia de abordaje

En un primer momento realizamos un value counts para los valores true y false, para verificar que la hipótesis tenga sentido. Una vez evaluada la coherencia de los datos, dividimos la cantidad de los que tienen gluten sobre la cantidad total de alimentos para obtener la proporción.

Luego para expresar las proporciones decidimos agregar un gráfico de torta, ya que solo tenemos dos resultados posibles. De esta forma quedan visualmente claros los resultados para justificar o desmentir la hipótesis.

No necesitamos limpiar la columna ya que todas estaban correctamente cargadas con los valores “TRUE” o “FALSE”.

3.1.3. Resultados obtenidos y discusión

A partir de nuestro análisis, obtuvimos que el 32,7% de los productos contenían gluten. **Estos datos terminaron no respaldando la hipótesis** y sorprendiéndonos, dado que siempre tuvimos la idea de que hoy en día la gran mayoría de los productos contienen gluten. Ya que para afirmar que un producto no tiene gluten, se deben cumplir con numerosos controles, estos resultados nos hacen pensar que el dataset tiende a contener muchos productos naturales o poco procesados.

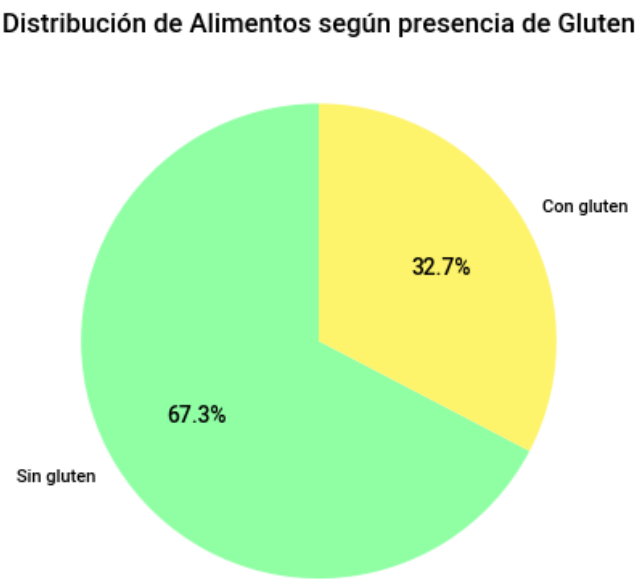


Fig. 4: Gráfico de torta, muestra la distribución de alimentos con y sin gluten.

3.2. Hipótesis 2: Verificar que, mientras más azúcares tenga el alimento cada 100 gramos, mayor es el Nutri Score.

3.2.1. Definición de la hipótesis

H0: No existe una relación entre sugars_100g y nutriscore_grade

El valor que brinda la hipótesis planteada sería poder confirmar que el azúcar es uno de los principales agravantes de la calidad nutricional de los alimentos.

3.2.2. Estrategia de abordaje

Para abordar la hipótesis, utilizamos la columna nutriscore_num que creamos en la limpieza del dataset (y eliminamos los valores nulos) para poder calcular un coeficiente de correlación que nos sirva como apoyo para justificar la hipótesis. Para este coeficiente utilizamos Spearman, ya que este permite calcular correlación que incluya variables cualitativas ordinales.

A nivel gráfico, al estar comparando una variable cualitativa ordinal (nutriscore_grade) con una cuantitativa continua (sugars_100g), decidimos utilizar un boxplot que nos permita conocer para cada nota nutricional la distribución de las cantidades de azúcar en los alimentos.

3.2.3. Resultados obtenidos y discusión

Al calcular el coeficiente de correlación, nos dio ~0,4413. Esto es positivo, lo que nos dice que, a medida que aumenta la cantidad de azúcares, el Nutri-Score tiende a empeorar. Al ser Spearman de -1 a 1, esta relación es moderada, por lo que existe una tendencia notable pero no es tan fuerte.

Los resultados no respaldan nuestra hipótesis, aunque la asociación no es lo suficientemente fuerte como para afirmar que la cantidad de azúcares únicamente define el Nutri-Score, y que esta métrica podría apoyarse sobre más variables.

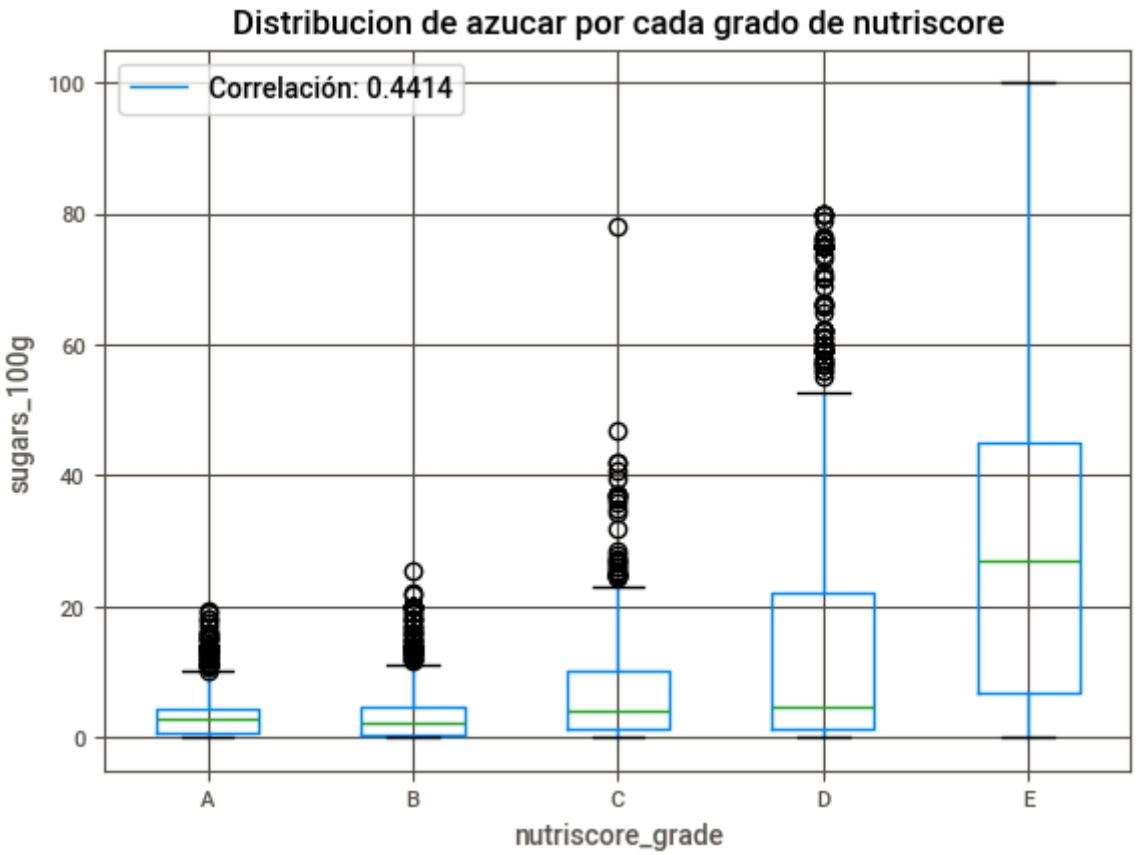


Fig. 5: Gráfico de boxplot, muestra las distribuciones de la cantidad de azúcar por cada nota Nutri-Score.

3.3. Hipótesis 3: Predecir grupo NOVA a partir de la información nutricional

3.3.1. Definición de la hipótesis

H0: El contenido energético, los azúcares, las grasas saturadas, las proteínas, los carbohidratos y la sal **no** explican conjuntamente la variabilidad del grado de procesamiento industrial de los alimentos.

A partir de esta hipótesis, podemos inferir que tan útil puede ser la tabla nutricional de un producto para saber qué tan procesado está. Cabe aclarar que, en un producto alimenticio, el Nutri-Score se relaciona con la tabla nutricional y el NOVA con la lista de ingredientes. Por ejemplo, una gaseosa light seguramente tenga valores bajos en la tabla nutricional (buen Nutri-Score) pero si vemos la lista de ingredientes vamos a ver que está super procesada.

3.3.2. Estrategia de abordaje

En este caso, hicimos una regresión lineal a partir de las variables de la tabla nutricional: energy_kcal, sugars_100g, saturated_fat_100g, proteins_100g, carbs_100g, salt_100g.

Luego hicimos un biplot a partir de una reducción de dimensionalidad por PCA de las variables mencionadas y pintamos los puntos con el color dependiendo del grupo NOVA.

3.3.3. Resultados obtenidos y discusión

Luego de ejecutar el test, obtuvimos un R cuadrado de 0.048 y un p-valor prácticamente cero, por lo que **no hay evidencia para rechazar la hipótesis nula**, la información nutricional no explica el grupo NOVA. En los resultados vemos que hay variables que no son significativas para la regresión, estas son energy_kcal, saturated_fat100g y salt_100g tienen un p-valor mayor a 0.05 y contienen al 0 en su intervalo de confianza.

En el gráfico, si bien sólo se captura el 55% de la varianza, podemos ver que los valores de NOVA están muy dispersos, por lo que no podemos decir que haya una relación con las variables de la tabla nutricional. Solo se aprecia, hacia la izquierda del gráfico, una concentración de NOVA 1, en productos con baja densidad energética, mientras que a la derecha del gráfico, vemos lo opuesto, con solo valores de NOVA 3 y 4. En algunas observaciones de NOVA 2, vemos que están muy aislados en valores extremos de ciertos nutrientes, lo cual nos dice que probablemente sean ingredientes puros (sales a la izquierda, aceites arriba a la derecha y azúcares abajo a la derecha).

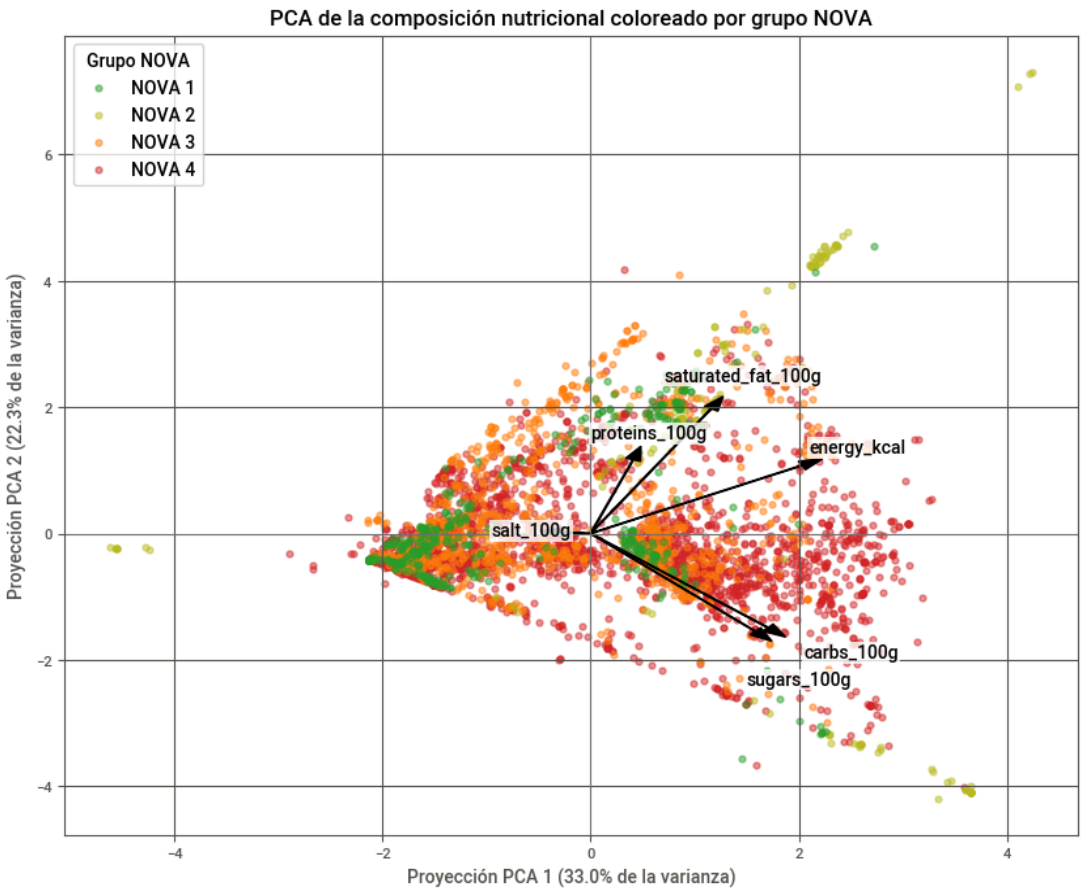


Fig. 6: Scatterplot y Biplot hechos a partir de un PCA de las variables de la composición nutricional coloreadas por cada valor de NOVA.

3.4. Hipótesis 4: Proporción de productos altos en grasas saturadas.

3.4.1. Definición de la hipótesis

H0: La proporción de productos catalogados como "altos en grasas saturadas" (más de 5 g de grasa saturada por cada 100 g de producto) en la población de referencia es superior al 25%.

Es sabido que muchos de los productos empaquetados que compramos día a día cuentan con niveles elevados de grasas saturadas debido a sus procesos de fabricación. A partir de este pensamiento, es útil chequear la proporción de alimentos altos en grasas saturadas en el dataset, que aborda una gran cantidad de comidas.

3.4.2. Estrategia de abordaje:

Para abordar esta hipótesis, eliminamos aquellos productos que no tenían definido un valor para las grasas saturadas para poder hacer un análisis de forma binaria según qué alimentos superan los 5 gramos.

Luego para verlo gráficamente hicimos un gráfico de torta, ya que al tener dos posibles resultados, queda muy fácil de entender.

3.4.3. Resultados obtenidos y discusión

Entre los alimentos que tenían definido un valor para este atributo, encontramos que el 30.6% posee más de 5 gramos de grasas saturadas por cada 100 gramos de producto. De esta forma **la hipótesis se acepta** ya que esta indicaba que el porcentaje debía superar el 25% para ser aceptada.

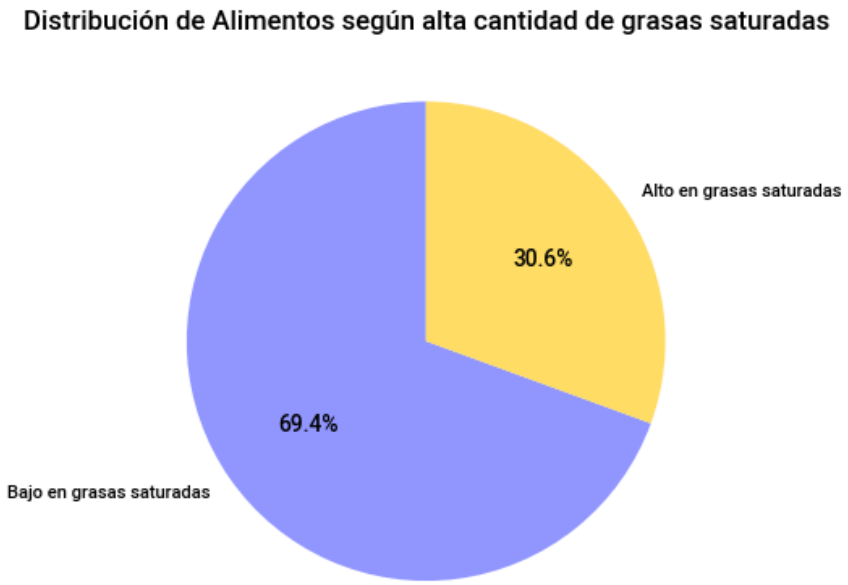


Fig. 7: Gráfico de torta, muestra la distribución de alimentos con alta y baja cantidad de grasas saturadas.

3.5. Hipótesis 5: Calificación de un alimento en relación a su procesamiento.

3.5.1. Definición de la hipótesis:

H0: El grado de procesamiento industrial de un alimento está asociado con la calificación nutricional Nutri-Score que recibe, de manera que los productos más procesados presentan calificaciones más desfavorables.

3.5.2. Estrategia de abordaje:

Como esta hipótesis relaciona dos variables cualitativas ordinales, decidimos nuevamente utilizar nutriscore_num para los cálculos. Al igual que en nuestra segunda hipótesis planteada, al haber incluídas variables cualitativas ordinales decidimos utilizar el coeficiente de correlación de Spearman para determinar qué tan relacionadas están las variables.

Para apoyar al coeficiente de correlación y darle una perspectiva más visual, decidimos utilizar un gráfico de barras múltiples, donde para cada valor de NOVA (ordenado ascendentemente) se muestran las barras que representan la cantidad de ocurrencias de cada puntaje de nutriscore (también ordenada ascendente).

3.5.3. Resultados obtenidos y discusión

Al ejecutar el código el valor de la correlación nos dió 0.319 con un p-valor muy cercano al cero. Esto nos dice que existe una correlación positiva débil entre las variables. Esto se puede ver en el gráfico ya que para el valor 1 de la variable NOVA se ven más ocurrencias de valor A de Nutri-Score, y en el valor 4 (NOVA), se ven muchas ocurrencias de notas negativas de Nutri-Score. Sin embargo, podemos encontrar ocurrencias de todas las notas de Nutri-Score dentro de cada valor de NOVA.

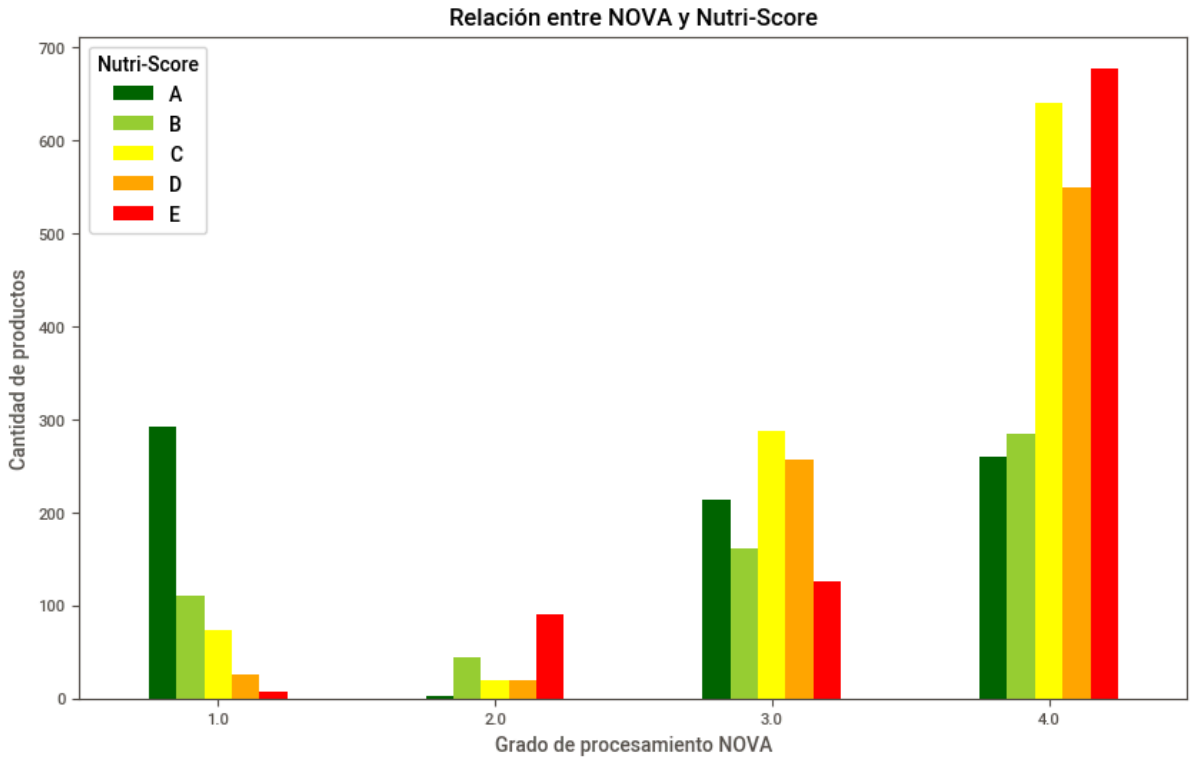


Fig. 8: Gráfico de barras múltiple que muestra para cada valor de NOVA, la cantidad de valores Nutri-score.

3.6. Hipótesis 6: Nutri-Score de un alimento en relación a procesamiento, categoría, y alérgenos.

3.6.1. Definición de la hipótesis

H0: El grado de procesamiento industrial (NOVA), la categoría del producto y la cantidad de alérgenos declarados explican conjuntamente la probabilidad de que un producto reciba una calificación Nutri-Score desfavorable (D/E), sin utilizar directamente su composición nutricional.

3.6.2. Estrategia de abordaje

Primero utilizamos una regresión lineal sobre las 2 variables numéricas (NOVA y cantidad de alérgenos) con Nuti-Score como variable dependiente, ya que la categoría no puede ser agregada en una regresión así como está.

Luego hicimos otra regresión, en esta ocasión una regresión lineal logística en la que definimos los valores D y E (4 y 5) de Nutri-Score como calificación desfavorable. Representamos las categorías con más de 500 apariciones en el dataset como columnas binarias para poder agregarlas a la regresión como variables.

3.6.3. Resultados obtenidos y discusión

En ambas regresiones conseguimos un R^2 muy bajo (0.151 y 0.1995), por lo que podemos rechazar la hipótesis concluyendo que no es posible explicar el Nutri-Score a partir de estas variables.

4. Conclusiones

A lo largo de este trabajo, utilizamos varias técnicas de análisis de datos para lograr un análisis sobre el dataset de Open Food Facts, que fue el dado. En este, hicimos estudios sobre las características de los alimentos, y sobre las relaciones entre las variables.

La principal dificultad que encontramos a la hora de abordar este trabajo fue la forma en la que se presentaron los datos en el dataset. Al tratarse de un dataset cargado de forma colaborativa, encontramos numerosos problemas como valores nutricionales inconsistentes, datos faltantes y categorías expresadas en diferentes idiomas. Esto causó que dediquemos una gran parte del tiempo invertido en el trabajo a la limpieza de los datos. Consideramos que la limpieza fue de las partes más importantes y sobre todo esencial para permitirnos estudiar el dataset.

En cuanto a las hipótesis que nos tocó plantear, encontramos resultados que contradijeron nuestras expectativas en casi todas las ocasiones, como en la primera sobre el gluten en los alimentos, o en la hipótesis sobre las grasas saturadas.
Nuestra hipótesis multivariada pudo encontrar correlaciones moderadas o débiles entre los niveles de azúcares y el grado de procesamiento, y una peor calificación Nutri-Score. Sin embargo, nuestros modelos de regresión fueron incapaces de explicar la mayor parte de la varianza, por lo que entendimos que las distintas clasificaciones de alimentos no necesariamente pueden explicarse unas a partir de otras.

Consideramos que el trabajo nos permitió comprender la importancia de cada etapa en el análisis de los datos, y que la gran limpieza necesaria nos preparó correctamente para en un futuro encontrarnos con datasets en situaciones similares. El trabajo nos permitió poner en práctica las herramientas estudiadas durante la materia y reconocer tanto sus posibilidades como sus limitaciones al aplicarlas sobre datos reales.

Referencias

Open Food Facts. (s. f.). Scores. https://world.openfoodfacts.org/scores